Análise de conjunto de dados de indicadores de diabetes

*Estudo e análise exploratória de um conjunto de dados de indicadores de saúde para prever casos de diabetes

1st Filipe Alcantara da Costa
dept. Engenharia de Teleinformática (DETI)
Universidade Federal do Ceará (UFC)
Fortaleza, Brasil
filipealcantara441@gmail.com

2nd Gustavo Oliveira Seabra
dept. Engenharia de Teleinformática (DETI)
Universidade Federal do Ceará (UFC)
Fortaleza, Brasil
gustavooliveiraseabra@alu.ufc.br

3rd Lucas de Oliveira Sobral
dept. Engenharia de Teleinformática (DETI)
Universidade Federal do Ceará (UFC)
Fortaleza, Brasil
sobrallucas33@gmail.com

4th Savlio Carvalho Pontes
dept. Engenharia de Teleinformática (DETI)
Universidade Federal do Ceará (UFC)
Fortaleza, Brasil
savliocp@alu.ufc.br

***Abstract*—Neste primeiro trabalho da disciplina de Inteligência Computacional Aplicada, realizamos a primeira etapa para nosso futuro modelo preditivo ou de inferência, sendo essa, a etapa de análise exploratória do dados, é a etapa mais importante e que leva maior tempo, seja no aprendizado estatístico ou aprendizado de máquina.**

Aqui estabelecemos o escopo e base para nosso futuro modelo, suas variáveis preditoras, seu objetivo e variável-alvo, verificamos erros da base de dados, transformamos seus preditores.

Para isso, utilizamos várias etapas de exploração, sendo elas: Pré-processamento de dados, Análise Univariada Condicional e Não-Condicional, Análise Bivariada Condicional e Não-Condicional, Análise Multivariada através da criação dos Componentes Principais (PCA).

Nossos resultados foram a definição de 6 preditores definitivos dentre os 22 totais, duas variáveis-alvo representada pela classe `Diabetes_binary` e `BMI` e duas componentes principais que explicam 59,41% dos dados, com o intuito de, futuramente, desenvolver um modelo capaz de prever e inferir se uma pessoa tem diabetes.

***Index Terms*—Análise Exploratória, Pré-processamento, PCA, Diabetes, Análise de dados**

I. Introdução

A diabetes é uma condição caracterizada pelo aumento do nível de glicose no sangue. O que ocorre quando o corpo de uma pessoa não produz suficientemente ou não consegue usar o hormônio insulina, responsável por levar a glicose às células. Essa condição pode ser tanto adquirida por influências genéticas, como também adquirida ao longo da vida, ligada a fatores como o sedentarismo, hábitos alimentares e sobrepeso. Em ambos os casos, a diabetes tem uma forte influência na vida da pessoa, ocasionando sintomas como fadiga, visão turva, perda de peso, feridas, dormência, sede e infecções.

No Brasil, essa condição é bem prevalente. Segundo o Ministério da Saúde, a frequência do diagnóstico foi de 10,2%, o que corresponde a cerca de 20 milhões da população, ocupando o sexto lugar entre países com mais pessoas com diabetes.

Em meio a esse cenário, este estudo faz uso de um dataset fornecido pela plataforma Kaggle: Conjunto de dados de indicadores de saúde para diabetes, com o intuito de fazer uma Análise Exploratória de Dados (EDA) para entender as características e hábitos de uma pessoa e sua relação com a diabetes.

Dos preditores do dataset, dois serão de maior relevância para as nossas análises: *Diabetes_binary*, representando se a pessoa tem diabetes ou não, e *BMI*, índice de massa corporal da pessoa. Essas serão nossas variáveis-alvo, as quais nos ajudarão a representar se os demais preditores são ou não úteis para a nossa análise.

Essa análise exploratória dos dados é importante para o entendimento do dataset como um todo. Identificando as nuances de cada preditor e a relação deles com os outros, o que ajudará em outros estudos para realizar modelos de regressão ou classificação. Isso por meio da redução da dimensionalidade do dataset, como também pela identificação de outliers e pela análise das relações de preditores com nossas variáveis-alvo.

II. Metodologia

Trata-se de uma análise de objetivo descritivo para entender a relação entre a diabetes e os demais preditores, uma utilizando, para isso, abordagem quantitativa, por meio da manipulação numérica do dataset. O estudo também foca na análise de caso para investigar e responder à pergunta central de qual é a relação da diabetes com outras características de uma pessoa, e qual característica está mais relacionada a essa condição, sendo, de natureza, uma pesquisa básica.

O estudo foi realizado usando o dataset do Kaggle referido integrado ao ambiente do Google Colab, para a utilização de Python. Foi utilizado das bibliotecas kagglehub, para a importação dos dados, numpy, pandas e scipy para a manipulação do dataset, além da seaborn e da matplotlib para o plot dos gráficos. Os gráficos foram criados com base no tipo de variável que estava sendo analisada em questão.

Então, a análise foi dividida em 4 partes: o entendimento e tratamento dos dados, a análise univariada, a análise bivariada e a análise multivariada.

A. Primeira análise dos dados

O primeiro passo foi importar o dataset do Kaggle. Esse dataset conta, a priori, com 70.692 amostras e 22 variáveis. Esse dataset é um dataset já identado de outro usado para uma pesquisa, logo ele não apresenta valores faltando e a quantidade de pessoas com diabetes é igual à de pessoas sem diabetes. Entretanto, ainda assim, irá conter amostras com valores duplicados e outliers.

Para evitar trabalhar com uma quantidade massiva de dados, visto que dificultaria a visualização, foi então feito um processo de tratamento. Primeiro foi feita uma randomização, para tirar o viés, e coleta de uma parte dos dados, com 6.000 amostras restantes. Após isso, foram retiradas amostras duplicadas.

Depois desse processo de tratamento, foi retirado o dataset de 5.983 amostras e 22 preditores. Os preditores constam com 3 tipos no total:

- 15 variáveis binárias, sendo elas: ”Diabetes_binary, HighBP, HighChol, CholCheck, Smoker, Stroke, HeartDiseaseorAttack, physActivity, Fruits, Veggies, HvyAlcoholConsump, AnyHealthcare, NoDocbcCost, DiffWalk e Sex”;
- 4 qualitativas ordinais: ”GenHlth, Age, Education e Income”;
- 3 quantitativas: ”MentHlth, PhysHlth, BMI (Body Mass Index)”.

Um objetivo para artigos posteriores a este é fazer um modelo de regressão e um de classificação. Para tanto, será escolhida uma variável principal de análise para cada modelo, as quais, desde já, serão tratadas como variáveis-alvo para o foco da análise. Para o modelo de regressão, precisamos de uma variável quantitativa; para tanto, o BMI foi escolhido. Já para a classificação, como o nosso objetivo é comparar a diabetes com os demais preditores, foi escolhido o preditor ”Diabetes_binary”.

A partir dessa escolha, o preditor ”Diabetes_binary” também foi escolhido para a separação por classes, o que será útil para a análise univariada dos preditores, sendo no total 2 classes: a 0, sem diabetes, e a 1, com diabetes.

O nosso objetivo com as análises é:

- Diminuir a dimensionalidade do dataset;
- Verificar a relação dos preditores com as variáveis-alvo;
- Verificar a relação dos preditores entre si.

Para tanto, em cada análise, serão mostrados gráficos para contribuir com esses objetivos.

B. Analise Univariada

Na análise Univariada, o nosso objetivo é analisar o tipo e o comportamento do preditor, além de comparar as classes de um mesmo preditor para verificar a relação com diabets. Procura-se preditores que tenham mais diferenças em casos com e sem diabets, para termos um aspecto de quais variaveis são mais relevantes para os modelos. Para tanto, foi feito tanto um plot das medidas de tendencias gerais, média, desvio padrão e assimetria, como tambem de graficos para a comparação entre classes, de acordo com o tipo de variavel.

Os graficos para a visualização, se relacionam muito com o tipo da variavel:

- Binarios: porcentagem de respostas afirmativas em relação ao total;
- Qualitativos: graficos de linhas ou densidade.
- Quantitativos: histogramas e boxplots;

1) Variaveis Binárias: Para a análise univariada dos preditores Binários, foi usado o grafico da figura 1. Nele, é possivel observar quantas amostras tem o valor 1 em relação ao total do preditor, em porcentagem. Em azul, está o dataset normal, já em laranja e verde, está a separação por classes de acordo com o preditor ”Diabets_Binary”.

Esse grafico consegue fornecer uma interpretação muito boa de um preditor conseguimos ver a tendencia, de forma que, quanto mais perto dos extremos, mais respostas iguais para um preditor irão ser comuns, já em relação a diabets, quanto mais proximo as duas cores estão, em seus maximos, menos relação aquele preditor terá com a diabets, ao passo que, quanto maior a variação, mais provavelmente o preditor estará relacionado à diabets. Como ”diabets_binary” é a variavel alvo, o foco estará em preditores que estejam mais ao centro e com mais variação entre as classes.

De acordo com esses dois critérios, foi possivel focar em alguns preditores mais relevantes para o caso, sendo eles:

- **HighChol**: se a pessoa tem coresterol alto;
- **HighBP**: se a pessoa tem pressão alta;
- **physActivity**: se a pessoa faz atividade física
- **DiffWalk**: se tem dificultade para andar em escadas;
- **HeartDiseaseorAttack**: se tem doença arterial ou já teve infarto;

2) Variaveis qualitativas: Para a análise das variaveis qualitativas, como possuem mais valores que somente dois, é necessário um grafico mais detalhado. Para tanto, foi escolhida a ultilização de um grafico de linhas representando a porcentagem de cada categoria em relação ao total, assim como no grafico da figura 4. Esse preditor, GentHlth, nivel de saúde, possui 5 classificações, indo de 1 a 5, sendo 1 excelente e 5 Pessimo. No grafico, é possivel ver a distribuição de cada classe, tanto para o dataset normal, em azul, como para as classes, laranja para sem diabets e verde para com diabets.

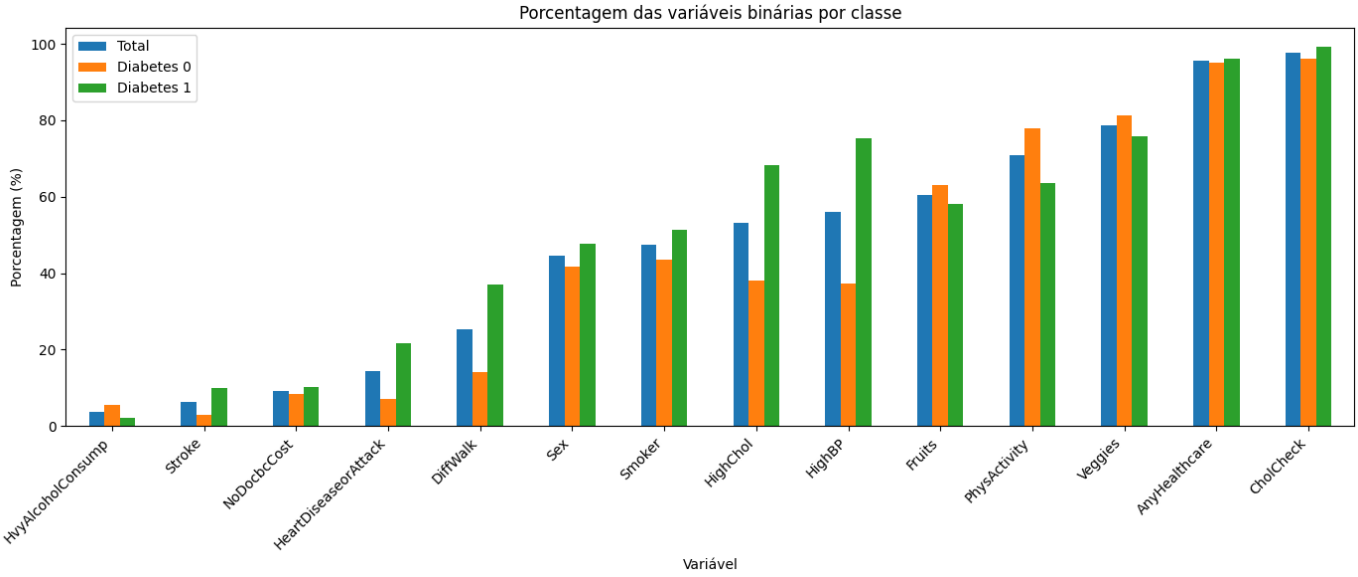


Fig. 1. Quantidade de respostas afirmativas em relação ao total das varivaveis binárias

Esse exemplo seve para mostrar como analisar esse tipo de grafico. É possivel ver um agrupamento de mais pessoas diabeticas em niveis altos, enquanto pessoas não diabeticas Estão agrupados para niveis baixos. Essa relação mostra como essa variável muda de acordo com o preditor ”Diabets_Binary”, sendo um grande indicativo que será útil para as análises.

O mesmo grafico foi feito para os demais preditores qualitativos, Age, Education e Income. Os preditores Age e GentHlth foram os que apresentaram maior variação, enquanto os preditores Income e Education, não mostraram tanta variação, porém ainda sendo relevantes.

Os preditores são:

- **GentHlth** Nível de sauúde, de 1 a 5, sendo 1 excelente e 5 pessima;
- **Age**: Categoria etária de 13 níveis segundo ”_AGEG5YR”;
- **Education**: Nível de escolaridade, de 1 a 6;
- **Income**: nível de renda, de 1 a 8.

3) Variaveis quantitatvas: Para a análise das variaveis quantitativas, como elas possuem mais valores possiveis, foi decidido fazer um histograma em conjunto para a analise de distribuição. O exemplo pode ser visto na figura 3, que representa o histrograma com a linha de densidade do preditor BMI. Em azul, está o dataset normal, em amarelo a classe sem diabetes e em verde, a calasse com diabets.

Por esses graficos é possível notar tanto a tendência de concentração, com um agrupamento em aproximadamente 30, como também as diferenças entre as classes. a classe com diabets parece estar deslocada para a direira, o que induz a pensar em uma relação leve entre os preditores, de forma que pessoas com diabetes tem mais BMI.

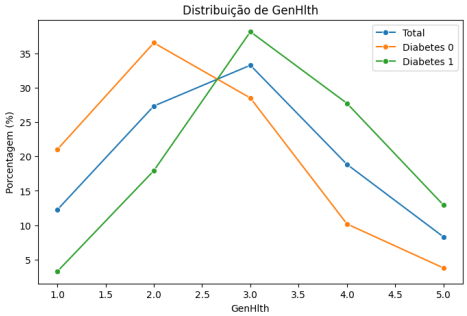


Fig. 2. Grafico de linhas, em porcentagem, do preditor GentHlth.

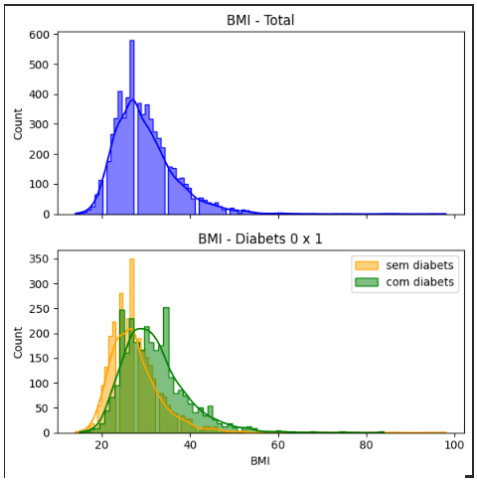


Fig. 3. histograma do preditor BMI, com e sem classificação.

Também foram feitos graficos similares para PhysHlth e MentHlth. Ambos tem uma concentração maior em 0, o PhysHlth parece ter um grande deslocamento em relação as classes com e sem diabets. Então, todos os preditores quantitativos parecem uteis para as análises.

Os preditores são:

- **BMI**: indice de massa corporal;
- **PhysHlth**: quantidade de dias com saúde física debilitada nos ultimos 30 dias;
- **MentHlth**: quantidade de dias com saúde mental debilitada nos ultimos 30 dias.

C. Análise Bivariada

D. Análise Multivariada

A Análise Multivariada neste trabalho implementou e utilizou a Análise de Componentes Principais (PCA), que é uma técnica estatística multivariada e de aprendizado não supervisionado, voltada para a redução de dimensionalidade e extração de características (feature extraction). Como é um método não supervisionado, ele não utiliza a variável resposta Y ou rótulos de classe para construir seus componentes.

A sua primeira aplicação seguiu os seguintes passos:

1) **Obter matriz de Covariância ou Correlação**: Levando em conta nosso dataset, que havia tanto dados contínuos quanto categóricos/binários, optamos por usar a Matriz de Correlação, pois ela é mais indicada para preditores que estão em escalas diferentes ou unidades de medidas diferentes, em oposição à de Covariância.
2) **Decomposição em Autovalores e Autovetores**: Após se obter a Matriz de Correlação, podemos calcular seus autovetores, que definem a direção e a orientação dos novos eixos ortogonais no espaço multidimensional, e seus autovalores, que representam a magnitude da variância explicada ao longo da direção do seu autovetor correspondente; por fim, deixá-los em ordem decrescente para que o maior e mais importante componente fique em primeiro na ordem.
3) **Cálculo da variância explicada**: Se trata do cálculo dos autovalores em ordem decrescente pela razão do somatório de todos os autovalores, multiplicado por cem para termos o cálculo em porcentagem, sendo o primeiro componente (PC_1) a combinação linear normalizada que maximiza a variância dos dados e o segundo componente principal (PC_2) o que captura a segunda maior fatia da variância dos dados, sob restrição de ser ortogonal (com correlação 0) ao PC_1.
4) **Projeção dos Dados (Factor Scores)**: E por fim podemos plotar o gráfico de calor (Heatmap) com os dois principais componentes ou todos os componentes principais, juntamente com o gráfico Biplot do PC_1 e PC_2, sendo justamente uma das vantagens da análise de componentes principais, pois não podíamos plotar um gráfico 2D com a nossa quantidade de preditores, mas com os dois principais componentes que explicam o conjunto de dados podemos observar seu comportamento vetorial.

Em sua segunda aplicação:

1) **Escolha dos preditores**: A primeira aplicação do PCA explicou apenas $24,54\%$ da variância acumulada. Além disso, a variável-alvo $Diabetes_binary$ havia sido incluída entre os preditores, o que causaria vazamento de dados no treinamento e no teste. Por isso, ela foi removida do cálculo.
2) **Remoção de Preditores por Multicolinearidade**: Sem a variável-alvo, a variância explicada aumentou para $34,60\%$. Avaliamos então a remoção de preditores redundantes por multicolinearidade, mas a maior correlação encontrada foi de apenas $0,51$, entre $DiffWalk$ e $PhysHlth$. Assim, essa abordagem não permitiria uma redução significativa.
3) **Combinação dos melhores preditores**: Como a baixa correlação impedia a seleção por redundância, aplicamos um algoritmo combinatório para avaliar subconjuntos com 4, 5, 6 e 7 preditores. Os melhores resultados são apresentados na Tabela I.
4) **Preditores definitivos**: A combinação de 6 preditores apresentou o melhor equilíbrio entre dimensionalidade e variância explicada acumulada ($59,41\%$): HighBP, HighChol, MentHlth, PhysHlth, Age e GenHlth.

TABLE I
MELHORES COMBINAÇÕES DE VARIÁVEIS SEGUNDO A VARIÂNCIA EXPLICADA POR PC1 E PC2.

Qtd. de variáveis	Variância explicada (%)	Variáveis
4	76,67	PhysHlth, Income, Education, GenHlth
5	67,73	MentHlth, PhysHlth, Income, Education, GenHlth
6	59,41	HighBP, HigChol, MentHlth, PhysHlth, Age, Income
7	54,20	HighBP, HighChol, MentHlth, PhysHlth, Age,Income...

III. RESULTADOS

A. Estrutura dos dados e checagens iniciais

O processo de amostragem aleatória e limpeza resultou em um conjunto final de 5.983 amostras e 22 preditores, livre de dados nulos. As checagens iniciais confirmaram o equilíbrio das classes na variável-alvo *Diabetes_binary* (proporção idêntica de indivíduos com e sem diabetes) e a presença de *outliers* e assimetria em variáveis contínuas, como o *BMI*, *PhysHlth* e *MentHlth*. Essas características reforçaram a necessidade de padronização prévia dos dados para a aplicação do PCA.

B. checagens finais

A análise univariada evidenciou comportamentos distintos entre os indivíduos com e sem diabetes ao longo das três categorias de preditores:

- **Preditores Binários**: A comparação percentual mostrou que o grupo com diabetes (classe 1) apresenta prevalências substancialmente maiores em diagnósticos clínicos e limitações físicas quando comparado ao grupo sem diabetes (classe 0). Pode-se observar esse comportamento em *HighBP* ($74,8\%$ x $37,2\%$), *HighChol* ($63,7\%$ x $37,8\%$), *DiffWalk* ($36,9\%$ x $13,2\%$) e *HeartDiseaseorAttack* ($18,6\%$ x $5,2\%$). Em contrapartida, a prática de atividade física (*PhysActivity*) foi menor entre os diabéticos ($63,1\%$ x $77,9\%$).
- **Preditores Qualitativos**: O preditor *GenHlth* (autoavaliação de saúde) demonstrou forte capacidade discriminatória: a classe sem diabetes concentrou-se nos níveis 1 e 2 (saúde excelente/boa), enquanto a classe com diabetes apresentou distribuição deslocada para os níveis 3, 4 e 5 (saúde razoável/ruim/pessima). A variável *Age* também confirmou que a prevalência de diabetes cresce de forma contínua com o avanço das faixas etárias. Os preditores socioeconômicos *Income* e *Education* indicaram leve tendência de menor renda e menor escolaridade no grupo afetado pela condição.
- **Preditores Quantitativos**: O *BMI* exibiu média superior na classe com diabetes ($31,87$ kg/m^2, desvio padrão $7,32$) em relação à classe sem diabetes ($27,78$ kg/m^2, desvio padrão $5,82$), com o histograma de densidade demonstrando um deslocamento nítido da curva à direita. Para *PhysHlth* e *MentHlth*, embora a mediana de ambas as classes seja zero, a média de dias com saúde física debilitada foi maior nos diabéticos ($7,90$ dias vs. $2,83$ dias nos últimos 30 dias).

C. Redundância e seleção

A avaliação de associação bivariada via coeficiente de correlação de Pearson revelou que, no geral, os preditores do conjunto de dados apresentam baixas correlações lineares interpessoais. A maior correlação observada ocorreu entre as variáveis *PhysHlth* e *DiffWalk* ($r = 0,51$), seguida por *GenHlth* e *PhysHlth* ($r = 0,50$).

A aplicação do algoritmo de filtragem por limiar de multicolinearidade confirmou a ausência de redundâncias extremas ($r > 0,80$), o que inviabilizou a eliminação direta de atributos por simples correlação de pares. Isso justificou o uso da abordagem combinatória com PCA para a escolha do melhor subconjunto reduzido.

D. Análise dos Componentes Principais (PCA) e Biplot

Ao aplicar a decomposição em autovalores e autovetores sobre a matriz de correlação do subconjunto definitivo de 6 variáveis selecionadas (*HighBP*, *HighChol*, *MentHlth*, *PhysHlth*, *Age* e *GenHlth*), escolhido a partir da busca combinatória detalhada na Tabela I, obteve-se a projeção dos dados em novos eixos ortogonais.

O primeiro componente principal (PC_1) capturou $39,26\%$ da variância total dos dados, sendo fortemente influenciado pelas cargas (*loadings*) dos preditores referentes ao estado geral de saúde física (*GenHlth* e *PhysHlth*). O segundo componente principal (PC_2) explicou $20,15\%$ da variância, apresentando maiores cargas associadas à saúde mental (*MentHlth*) e à faixa etária (*Age*).

Em conjunto, os dois primeiros componentes explicam $59,41\%$ da variância explicada acumulada, conforme registrado para a combinação de 6 variáveis na Tabela I. A análise do gráfico *Biplot* resultante confirmou que a projeção ortogonal no plano $PC_1 \times PC_2$ consegue agrupar os vetores de diagnósticos clínicos e saúde física de forma convergente, validando a redução da dimensionalidade do dataset de 22 para 6 preditores essenciais sem perda crítica de informação.

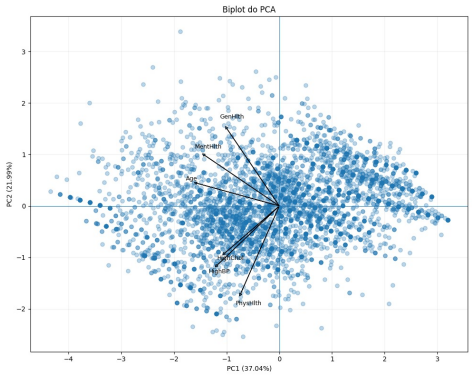


Fig. 4. Grafico Biplot entre PC1 e PC2.

REFERENCES

[1] Nerd dos Dados, ‘ ANÁLISE DE DADOS UNIVARIADA E BIVARIADA.”.
[2] FM2S, “Gráfico de dispersão: para que serve e como interpretar.”.
[3] DataCamp, “Understanding skewness and kurtosis.”.
[4] Domo, “Density plots.”.
[5] Analytics Vidhya, “Exploratory data analysis in Python.”.
[6] M. Waskom, “Visualizing categorical data,” Seaborn Documentation.
[7] D. Navarro and E. Weed, “Categorical data analysis,” *Learning Statistics with Python*.
[8] Laura Data Talks, “ O jeito MAIS FÁCIL de usar Kaggle no Google Colab.”.
[9] M. Waskom, “Visualizing distributions of data,” Seaborn Documentation.
[10] Sociedade Brasileira de Diabetes, “Brasil já tem cerca de 20 milhões de pessoas com diabetes.”.
[11] M. Rigonatto, “Como fazer um resumo ou abstract,” Mundo Educação.
[12] Editora Dialética, “Como escrever metodologia do artigo.”.
[13] Cleveland Clinic, “Diabetes.”.